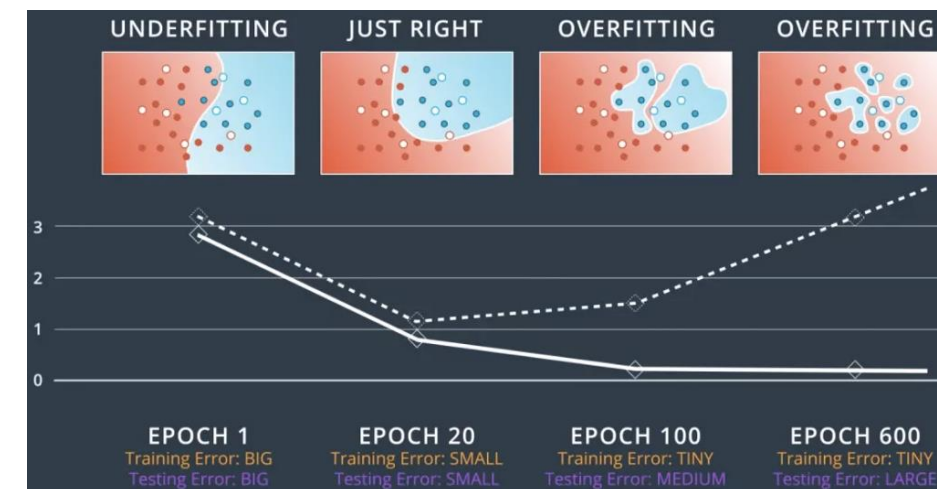




# Лекция 1. Искусственный интеллект и основы машинного обучения (МО) / Artificial Intelligence (AI) and Machine Learning (ML) basics

1. Область исследования и основные понятия / **Terms**
2. Линейная и полиномиальная регрессия / **Linear and polynomial regression**
3. Логистическая регрессия / **Logistic regression**
4. Настройка МО / **ML settings**




[ML settings intuition](#)

# Область исследования и основные понятия / Terms

## Математическое моделирование / Modeling

### Детерминированное / Deterministic

### Стохастическое / Stochastic



$$\frac{d^2 x}{dt^2} = -g;$$




$$V(0) = V_0, \quad x(0) = x_0.$$

$$a = -g,$$

$$V = -gt + V_0,$$




$$x = -\frac{gt^2}{2} + V_0 t + x_0.$$

Эксперимент и точное решение






Время, с

Аппроксимация x, расчет V, a



Время, с

Аппроксимация a, расчет V, x



Время, с

# Область исследования и основные понятия / Terms

“When I use a word,” Humpty Dumpty said in rather a scornful tone,  
“it means just what I choose it to mean—neither more nor less.”

[Through the looking glass](#)

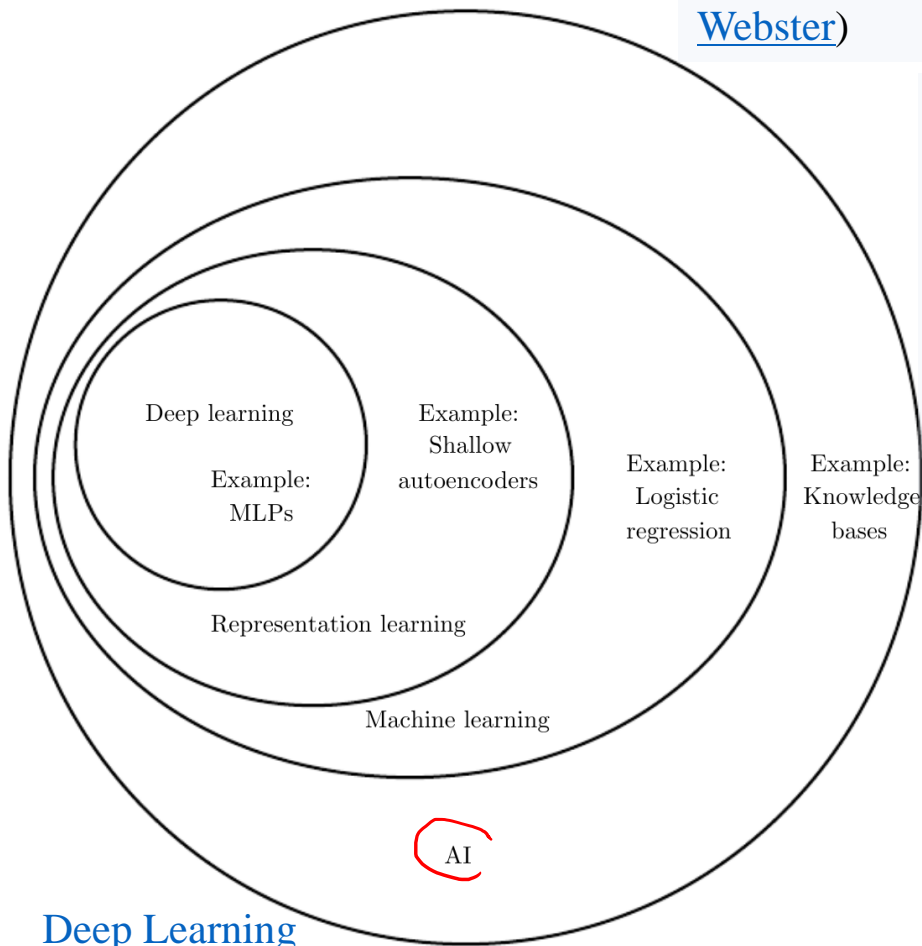
## Искусственный интеллект / Artificial Intelligence (AI):

область информатики, занимающаяся моделированием разумного поведения в компьютерах / a branch of computer science dealing with the simulation of intelligent behavior in computers ([Merriam-Webster](#))

## Машинное обучение / Machine Learning (ML):

область знаний, в которой компьютеры обучаются без явного программирования / field of study that gives computers the ability to learn without being explicitly programmed (Arthur Samuel, 1959);

задача «З», в ходе решения которой программа обучается из опыта «О» и повышает меру качества «К» / well-posed learning problem: a computer program is said to learn from experience E with respect to some task T and some performance measure P, if its performance on T, as measured by P, improves with experience E (Tom Mitchell, 1998)



Идея / Idea

+

Подход / Approach

+

Средства / Tools

AI

ML

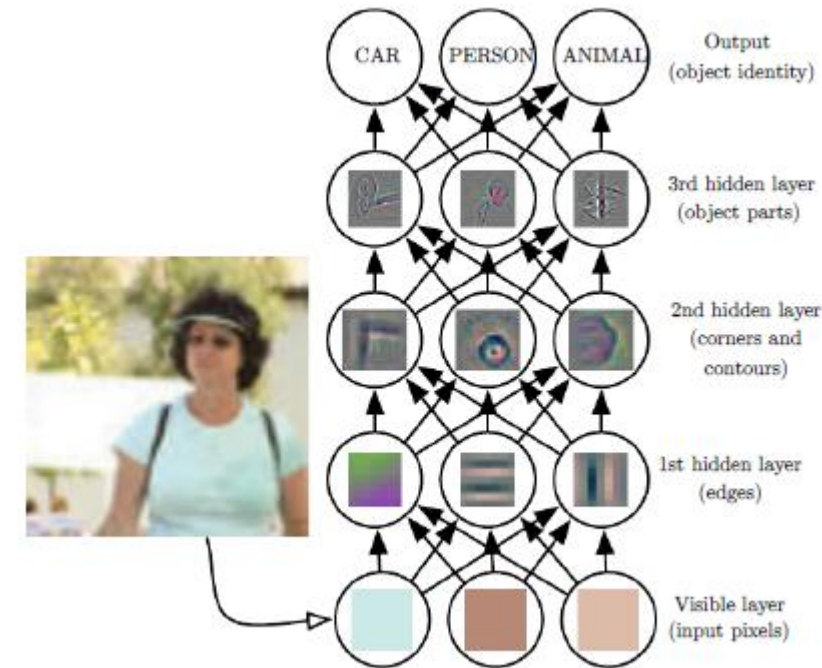
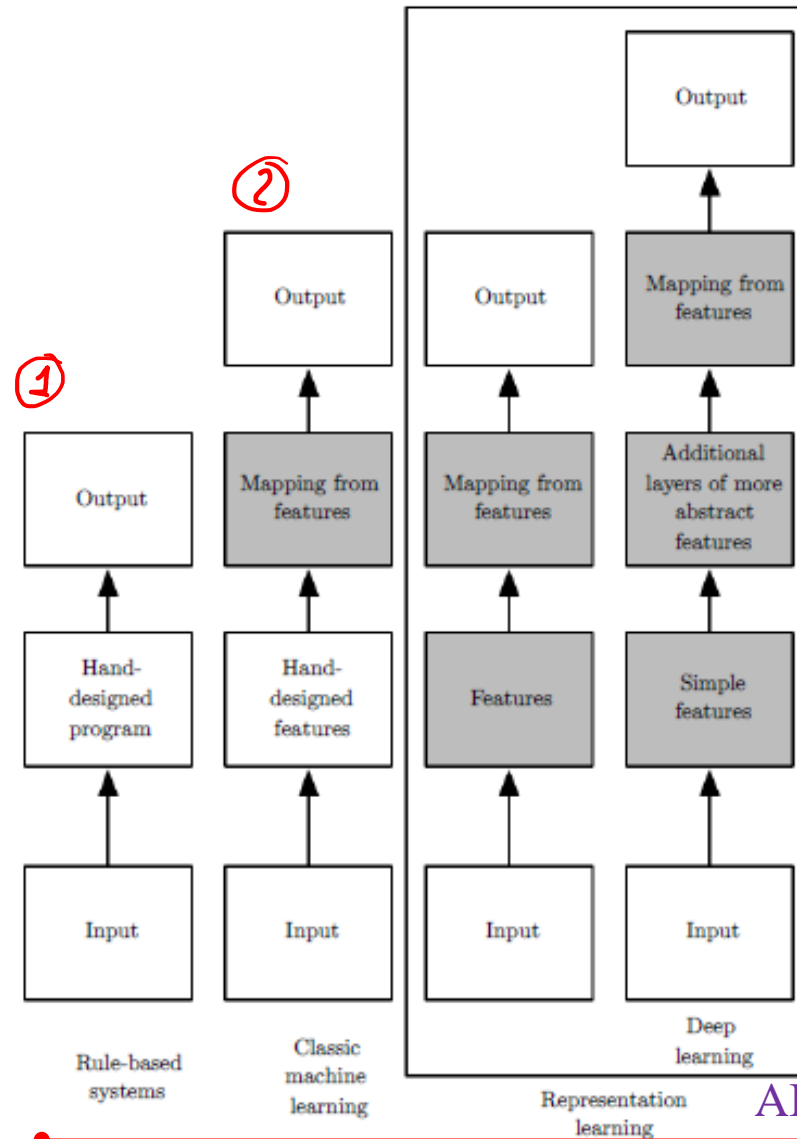
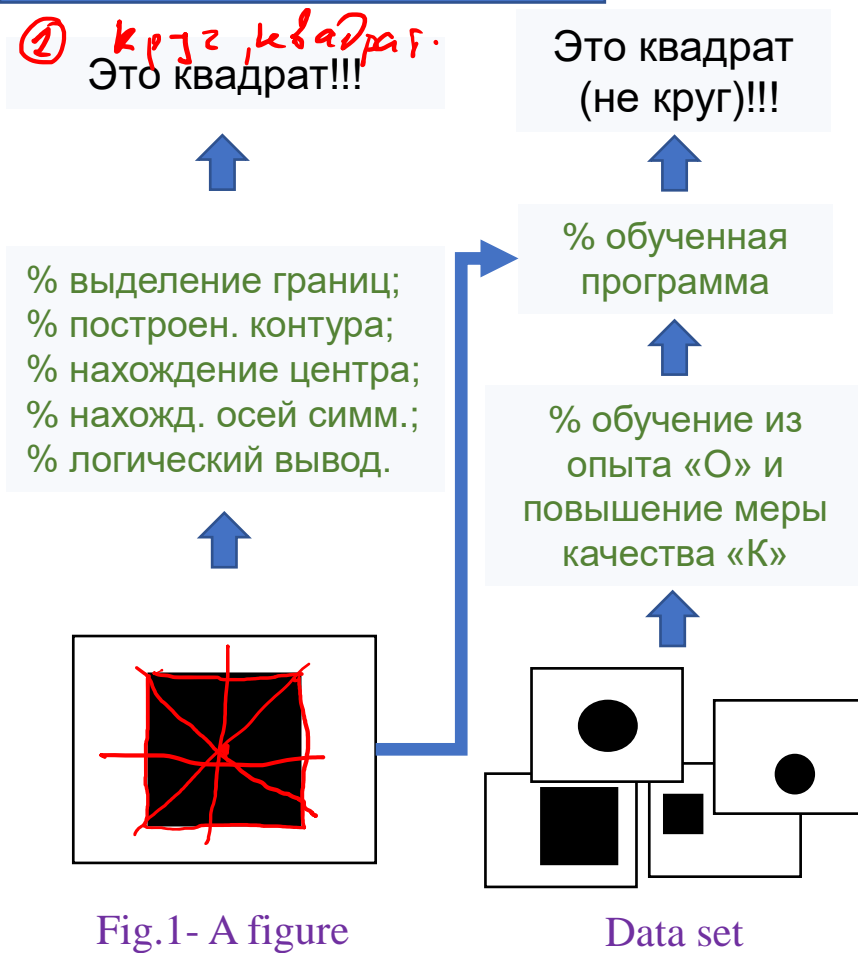
ANN  
DATA

# Область исследования и основные понятия / Terms

## Машинное обучение / ML

### Признаки / Features:

свойства объекта исследования, выделяемые при обучении



Deep Learning




# Область исследования и основные понятия / Terms

## Машинное обучение / ML

Обучение без учителя /  
Unsupervised learning

...Обучение с подкреплением /  
Reinforcement learning...

Обучение с учителем /  
Supervised learning



Types of Machine Learning and Examples of Applications

# Зачем это нужно? Что нужно знать, чтобы начать?

## Где об этом почитать? / FAQs

### Машинное обучение в жизни / ML applications

**Дома, в компьютере, в тел.:**  
поисковые системы, голосовые команды, переводчики, спам-фильтры, игры, обработки фото, новости, реклама, поиск друзей, *создание семей ...*

**На улице:**  
прогноз погоды, навигация, распознавание лиц, номеров автомобилей, *беспилотный транспорт...*

**На работе, в обществ. местах:**  
автоматизация и управление, *роботизация*, ассортимент товаров, диагностика, лечение...

# Зачем это нужно? Что нужно знать, чтобы начать?



## Где об этом почитать? / FAQs

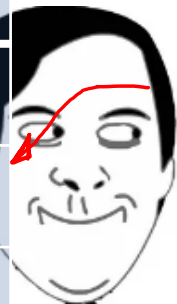
### Основы машинного обучения / ML Basics

#### Линейная алгебра / Linear algebra +

#### Мат. анализ / Calculus +

#### Теор. вер. / Probability theory

Название	Геом. аналог	Обозначения (в N-мерном протр.)	Кол-во компонент
Скаляр	.	$a$	$N^0 = 1$
Вектор		$\vec{a}, A, [a_i]$	$N^1$
Тензор		$T_a = [a_{ij}]$	$N^2$
...		$T^n = [a_{i_1 \dots i_n}]$	$N^n$
М-ца-строка (столбец)		$A = ((a_i))$	$N^1$
Матрица		$A = ((a_{ij}))$	$N^2$
...		$A = ((a_{i_1 \dots i_n}))$	$N^n$



$$\nabla a = \left[ \begin{array}{c} \cancel{\partial a} \\ \partial x_i \end{array} \right]$$

The **expectation** of some function  $f(x)$  with respect to a probability distribution  $p(x)$ :


$$E(f(x)) = \sum_x p(x) f(x).$$

The conditional maximum likelihood estimator:

$$\Theta_{ML} = \operatorname{argmax} \sum_{i=1}^m \log(p(y^{(i)} | x^{(i)}; \Theta)).$$

Bellman Expectation Equation for State-Action Value Function (Q-Function):

$$q_{\pi}(s, a) = E_{\pi}[R_{t+1} + \gamma q_{\pi}(s_{t+1}, a_{t+1}) | s_t = s, a_t = a].$$



[Google Parkour](#)



# Полезные ссылки / Links

## Онлайн курсы, обучающие ресурсы:

[Neural Networks](#): серия видео с отличной визуализацией с канала «3Blue1Brown» на английском языке, плюс видео с русским дублированием на смежном канале;

- ✓ [Andrew Ng – Machine Learning](#): 11-недельный бесплатный интерактивный курс на английском языке по основам машинного обучения на платформе [«Coursera»](#);
- [simOnsays – Deep Learning на пальцах](#): бесплатный видео курс лекций на русском языке, плюс на канале есть ссылка на ресурс с полным курсом и заданиями;
- [Kaggle](#): курсы, базы данных для машинного обучения (дата сеты), соревнования на английском языке.

## Книги, статьи:


[Deep Learning](#) by Ian Goodfellow and Yoshua Bengio and Aaron Courville, 2016.

Pattern Recognition and Machine Learning by C.M. Bishop, 2006.

Machine Learning: A Probabilistic Perspective by K.P. Murphy, 2012.


[Elsevier](#) , [Springer](#) : поисковые системы статей крупнейших издательств

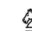
[SJR](#) , [WoS](#) : поисковые системы журналов, рейтинг журналов



Christopher M. Bishop

Pattern Recognition and  
Machine Learning



 Springer




**Machine Learning**  
A Probabilistic Perspective

Kevin P. Murphy



# Лекция 1. Искусственный интеллект и основы машинного обучения (МО) / Artificial Intelligence (AI) and Machine Learning (ML) basics

1. Область исследования и основные понятия / Terms
2. Линейная и полиномиальная регрессия / Linear and polynomial regression
3. Логистическая регрессия / Logistic regression
4. Настройка МО / ML settings




[ML settings intuition](#)

# Все начиналось с линейной регрессии / Linear regression

**Регрессионный** (от лат. regressio – обратное движение, отход) **анализ:**

набор статистических действий для оценки связи зависимой переменной и одной или нескольких независимых переменных ([Wikipedia](#))




Основная идея линейной регрессии: поиск наилучшей функциональной зависимости множества  $Y = ((y_i))$  от множества  $X = ((x_i))$  ( $i=1...m$ ) по критерию минимума некоторой функции качества:



$$X = \begin{pmatrix} x^{(1)} \\ \vdots \\ x^{(m)} \end{pmatrix}; Y = \begin{pmatrix} y^{(1)} \\ \vdots \\ y^{(m)} \end{pmatrix}; \Theta = \begin{pmatrix} \theta_0 \\ \theta_1 \end{pmatrix};$$


$$\tilde{J}(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h^{(i)} - y^{(i)})^2 \Rightarrow \min.$$


Cost function





# Все начиналось с линейной регрессии / Linear regression

Лирическое отступление. Метод градиентного спуска (подъема)

$$\vec{c} = \begin{bmatrix} \frac{y^{(2)} - y^{(1)}}{s_1} & \frac{y^{(4)} - y^{(2)}}{s_2} \end{bmatrix}$$




$$s_1, s_2 \rightarrow 0$$
$$\vec{g} = \begin{bmatrix} \frac{\partial J}{\partial \theta_0} & \frac{\partial J}{\partial \theta_1} \end{bmatrix}$$



Want to know more?  
[DeepMind x UCL | Deep Learning Lectures | 5/12 | Optimization for Machine Learning](#)

Пруд

[Gradient descent intuition](#)

# Все начиналось с линейной регрессии / Linear regression

## Лирическое отступление 2. Действия над матрицами

$$A = ((a_{ij})) = \begin{matrix} \overset{1}{\underset{3}{\text{1}}} & \overset{2}{\underset{3}{\text{2}}} & \overset{3}{\underset{3}{\text{3}}} \\ \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} \end{matrix}$$

$i, j = 1 \dots 3$   
 $\overset{2}{\text{1}} \rightarrow$  М-ца  $\overset{2}{\text{2}}$ 0 разнх  $\delta$   $\overset{3}{\text{3}}$ мерном пр-стве.  
 $\text{N}^\circ$  строки  $\text{N}^\circ$  столбца

$a_{ij}$

$\text{1 1}$

$1, 2, 3$

$a_{ij}$

$$a_{ii} \leftrightarrow a_{11} + a_{22} + a_{33}$$

1 1  
1 2  
1 3  
2 1  
2 2  
2 3  
3 1  
3 2  
3 3

$$c_{11} = a_{11}b_{11} + a_{12}b_{21} + a_{13}b_{31}$$

$$c_{11} = a_{11}b_{11} \quad c_{12} = a_{12}b_{12} \dots$$

$$\begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} \begin{pmatrix} b_{11} & b_{12} & b_{13} \\ b_{21} & b_{22} & b_{23} \\ b_{31} & b_{32} & b_{33} \end{pmatrix}$$

1. Умножение матрицы на число:

$$C = \alpha A, \quad c_{ij} = \alpha a_{ij}.$$

2. Сложение матриц:

$$C = A + B, \quad c_{ij} = a_{ij} + b_{ij}.$$

3. Транспонирование матрицы

$$A^T, \quad a_{ij}^T = a_{ji}.$$

4. Обратная матрица

$$A^{-1}, \quad AA^{-1} = I. \quad \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

5. Умножение матриц:

$$C = AB, \quad c_{ij} = a_{ik}b_{kj}.$$

5\*. Скалярное произведение тензоров:

$$c = T_A \cdot T_B, \quad c_{ij} = a_{ij}b_{ij}.$$

6. Дифференцирование и интегрирование полей

матричных и тензорных величин:

$$C = \frac{\partial A}{\partial x}, \quad c_{ij} = \frac{\partial a_{ij}}{\partial x}.$$

$$C = \int A dx, \quad c_{ij} = \int a_{ij} dx.$$




# Все начиналось с линейной регрессии / Linear regression

**Регрессионный** (от лат. regressio – обратное движение, отход) **анализ**:

набор статистических действий для оценки связи зависимой переменной и одной или нескольких независимых переменных ([Wikipedia](#))

Основная идея линейной регрессии: поиск наилучшей функциональной зависимости множества  $Y = ((y^{(i)}))$  от множества  $X = ((x^{(i)}))$  ( $i=1 \dots m$ ) по критерию минимума некоторой функции качества:



$$X = \begin{pmatrix} x^{(1)} \\ \vdots \\ x^{(m)} \end{pmatrix}; Y = \begin{pmatrix} y^{(1)} \\ \vdots \\ y^{(m)} \end{pmatrix}; \Theta = \begin{pmatrix} \theta_0 \\ \theta_1 \end{pmatrix};$$

$$H = X\Theta,$$

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h^{(i)} - y^{(i)})^2 \Rightarrow \min,$$

$$\nabla J = \begin{bmatrix} \frac{\partial J}{\partial \theta_0} & \frac{\partial J}{\partial \theta_1} \end{bmatrix}$$

$$\rightarrow \bar{X}^T \cdot \begin{pmatrix} 1 & x^{(1)} \\ \vdots & \vdots \\ 1 & x^{(m)} \end{pmatrix} \begin{pmatrix} \theta_0 \\ \theta_1 \end{pmatrix} = \begin{pmatrix} \theta_0 + x^{(1)}\theta_1 \\ \vdots \\ \theta_0 + x^{(m)}\theta_1 \end{pmatrix}$$

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h^{(i)} - y^{(i)})$$
$$\frac{\partial J}{\partial \theta_1} = \frac{1}{m} \sum_{i=1}^m (h^{(i)} - y^{(i)}) x^{(i,2)}$$

$$\nabla J = \frac{1}{m} X^T (H - Y).$$

Алгоритм поиска минимума функции качества.

1. Задать начальные значения компонент матрицы  $\Theta$  случайным образом.
2. Рассчитать функцию гипотезы  $H = X\Theta$  и вектор градиента функции качества:  $\nabla J = \frac{1}{m} X^T (H - Y)$ .
3. Зная текущие значения компонент (индекс «С») матрицы  $\Theta$  найти новые значения компонент (индекс «Н»), двигаясь в направлении, противоположном направлению вектора градиента, с шагом, характеризуемым параметром скорости обучения  $\alpha$ :  
 $\Theta^H = \Theta^C - \alpha \nabla J$ , или в скалярной форме  $\theta_0^H = \theta_0^C - \alpha \frac{\partial J}{\partial \theta_0}$ ,  $\theta_1^H = \theta_1^C - \alpha \frac{\partial J}{\partial \theta_1}$ .
4. Повторять пункты 2-3 до достижения минимума  $J$  по условию малости изменения значения функции на двух соседних итерациях или по условию достижения максимального количества итераций:  $J^H - J^C < \delta$ ,  $\# \text{итер.} > N_{\max}$ .
5. Вывод результатов:  $\Theta$ .

# Все начиналось с линейной регрессии / Linear regression

Регрессия / Regression

Линейная /  
Linear

Нелинейная /  
Non-Linear

Одна переменная (признак) /  
One variable (feature)

Мн. переменных / Multiple  
variables (features)

$$h(\theta_0, \theta_1) = \theta_0 + \theta_1 x$$

$$X = \begin{pmatrix} \begin{pmatrix} x^{(1)} \\ \vdots \\ x^{(m)} \end{pmatrix} \end{pmatrix}; Y = \begin{pmatrix} \begin{pmatrix} y^{(1)} \\ \vdots \\ y^{(m)} \end{pmatrix} \end{pmatrix}$$

Training data  $(X, Y)$

Learning Algorithm  $\theta_0, \theta_1$

$x \rightarrow h$

**Батч** / Batch: на каждом шаге град. спуска используются все обучающие данные.

$$h(\theta_0, \theta_j) = \theta_0 + \theta_k x_k, (j, k = 1 \dots n)$$

$$X = \begin{pmatrix} \begin{pmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \dots & x_n^{(1)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & x_2^{(m)} & \dots & x_n^{(m)} \end{pmatrix} \end{pmatrix}; Y = \begin{pmatrix} \begin{pmatrix} y^{(1)} \\ \vdots \\ y^{(m)} \end{pmatrix} \end{pmatrix}; \Theta = \begin{pmatrix} \begin{pmatrix} \theta_0 \\ \vdots \\ \theta_n \end{pmatrix} \end{pmatrix}$$

$$H = X\Theta, \quad \begin{matrix} m, 1 & [m, n+1] \\ \downarrow & [n+1, 1] \end{matrix}$$

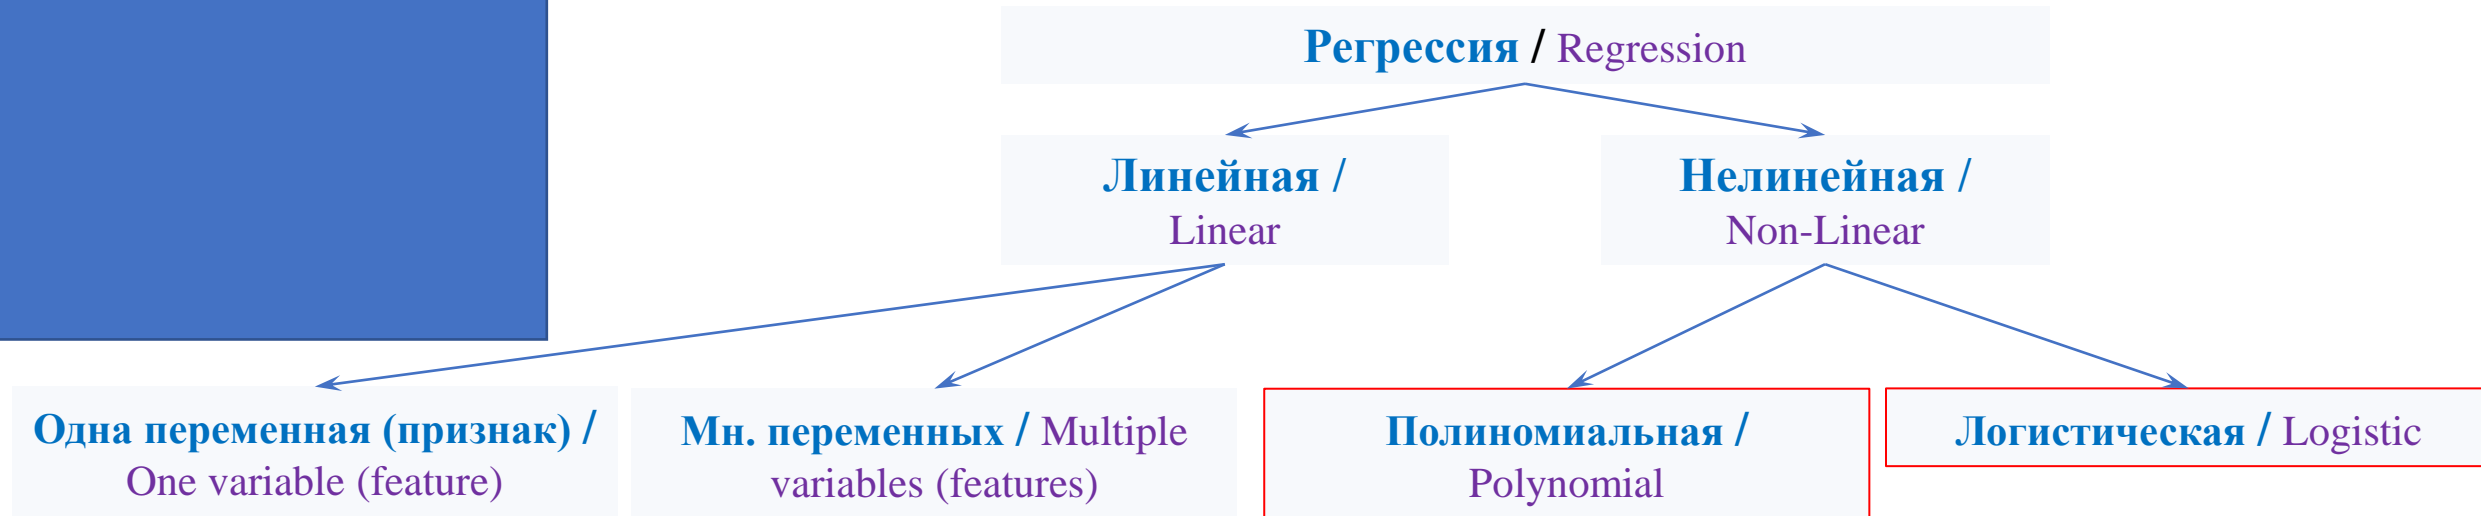
$$J(\theta_0, \theta_j) = \frac{1}{2m} \sum_{i=1}^m (h^{(i)} - y^{(i)})^2 \Rightarrow \min.$$

Алгоритм поиска минимума функции качества.

1. Задать нач.зн.  $\Theta$  случ. образом.
2. Рассч.  $H = X\Theta$  и  $\nabla J = \frac{1}{m} X^T (H - Y)$ .
3. Найти  $\Theta^H$  :  $\Theta^H = \Theta^C - \alpha \nabla J$ .
4. Повторять пункты 2-3 до выполнения одного из условий:  $J^H - J^C < \delta$ , #итер.  $> N_{max}$ .
5. Вывод результатов:  $\Theta$ .




# Полиномиальная регрессия / Polynomial regression



$$h(\theta_0, \theta_1) = \theta_0 + \theta_1 x$$

$$X = \begin{pmatrix} \begin{pmatrix} x^{(1)} \\ \vdots \\ x^{(m)} \end{pmatrix} \end{pmatrix}.$$



$$h(\theta_0, \theta_j) = \theta_0 + \theta_k x_k, (j, k = 1 \dots n)$$


$$X = \begin{pmatrix} \begin{pmatrix} x_1^{(1)} & x_2^{(1)} & \dots & x_n^{(1)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(m)} & x_2^{(m)} & \dots & x_n^{(m)} \end{pmatrix} \end{pmatrix}.$$



$$h(\theta_0, \theta_j) = \theta_0 + \theta_k x^k, (j, k = 1 \dots n)$$




$$x^i \rightarrow x_i$$

$$x^2 \rightarrow x_2$$



# Лекция 1. Искусственный интеллект и основы машинного обучения (МО) / Artificial Intelligence (AI) and Machine Learning (ML) basics

1. Область исследования и основные понятия / **Terms**
2. Линейная и полиномиальная регрессия / **Linear and polynomial regression**
3. Логистическая регрессия / **Logistic regression**
4. Настройка МО / **ML settings**




[ML settings intuition](#)

# Логистическая регрессия и решение задач классификации / Logistic regression and classification

Основная идея: поиск наилучшей функциональной зависимости бинарного множества  $Y = ((y_i))$  от множества  $X = ((x_i))$  ( $i=1 \dots m$ ) по критерию минимума некоторой функции качества:


$$J(\Theta) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \ln(h^{(i)}) + (1 - y^{(i)}) \ln(1 - h^{(i)})) \Rightarrow \min.$$



$$J(\Theta) = \frac{1}{2m} \sum_{i=1}^m (h^{(i)} - y^{(i)})^2 \Rightarrow \min.$$



$$J(\Theta) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \ln(h^{(i)}) + (1 - y^{(i)}) \ln(1 - h^{(i)})) \Rightarrow \min.$$



# Логистическая регрессия и решение задач классификации / Logistic regression and classification

Основная идея: поиск наилучшей функциональной зависимости бинарного множества  $Y = ((y_i))$  от множества  $X = ((x_i))$  ( $i=1 \dots m$ ) по критерию минимума некоторой функции качества:

$$J(\Theta) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \ln(h^{(i)}) + (1 - y^{(i)}) \ln(1 - h^{(i)})) \Rightarrow \min.$$

$$X = \left( \begin{pmatrix} x^{(1)} \\ \dots \\ x^{(m)} \end{pmatrix} \right); Y = \left( \begin{pmatrix} y^{(1)} \\ \dots \\ y^{(m)} \end{pmatrix} \right); \quad \rightarrow \quad X = \left( \begin{pmatrix} 1 & x^{(1)} \\ \dots & \dots \\ 1 & x^{(m)} \end{pmatrix} \right); \Theta = \begin{pmatrix} \theta_0 \\ \theta_1 \end{pmatrix}; Z = X\Theta; \quad \rightarrow \quad h(z) = \frac{1}{1 + e^{-z(x)}}, \rightarrow$$

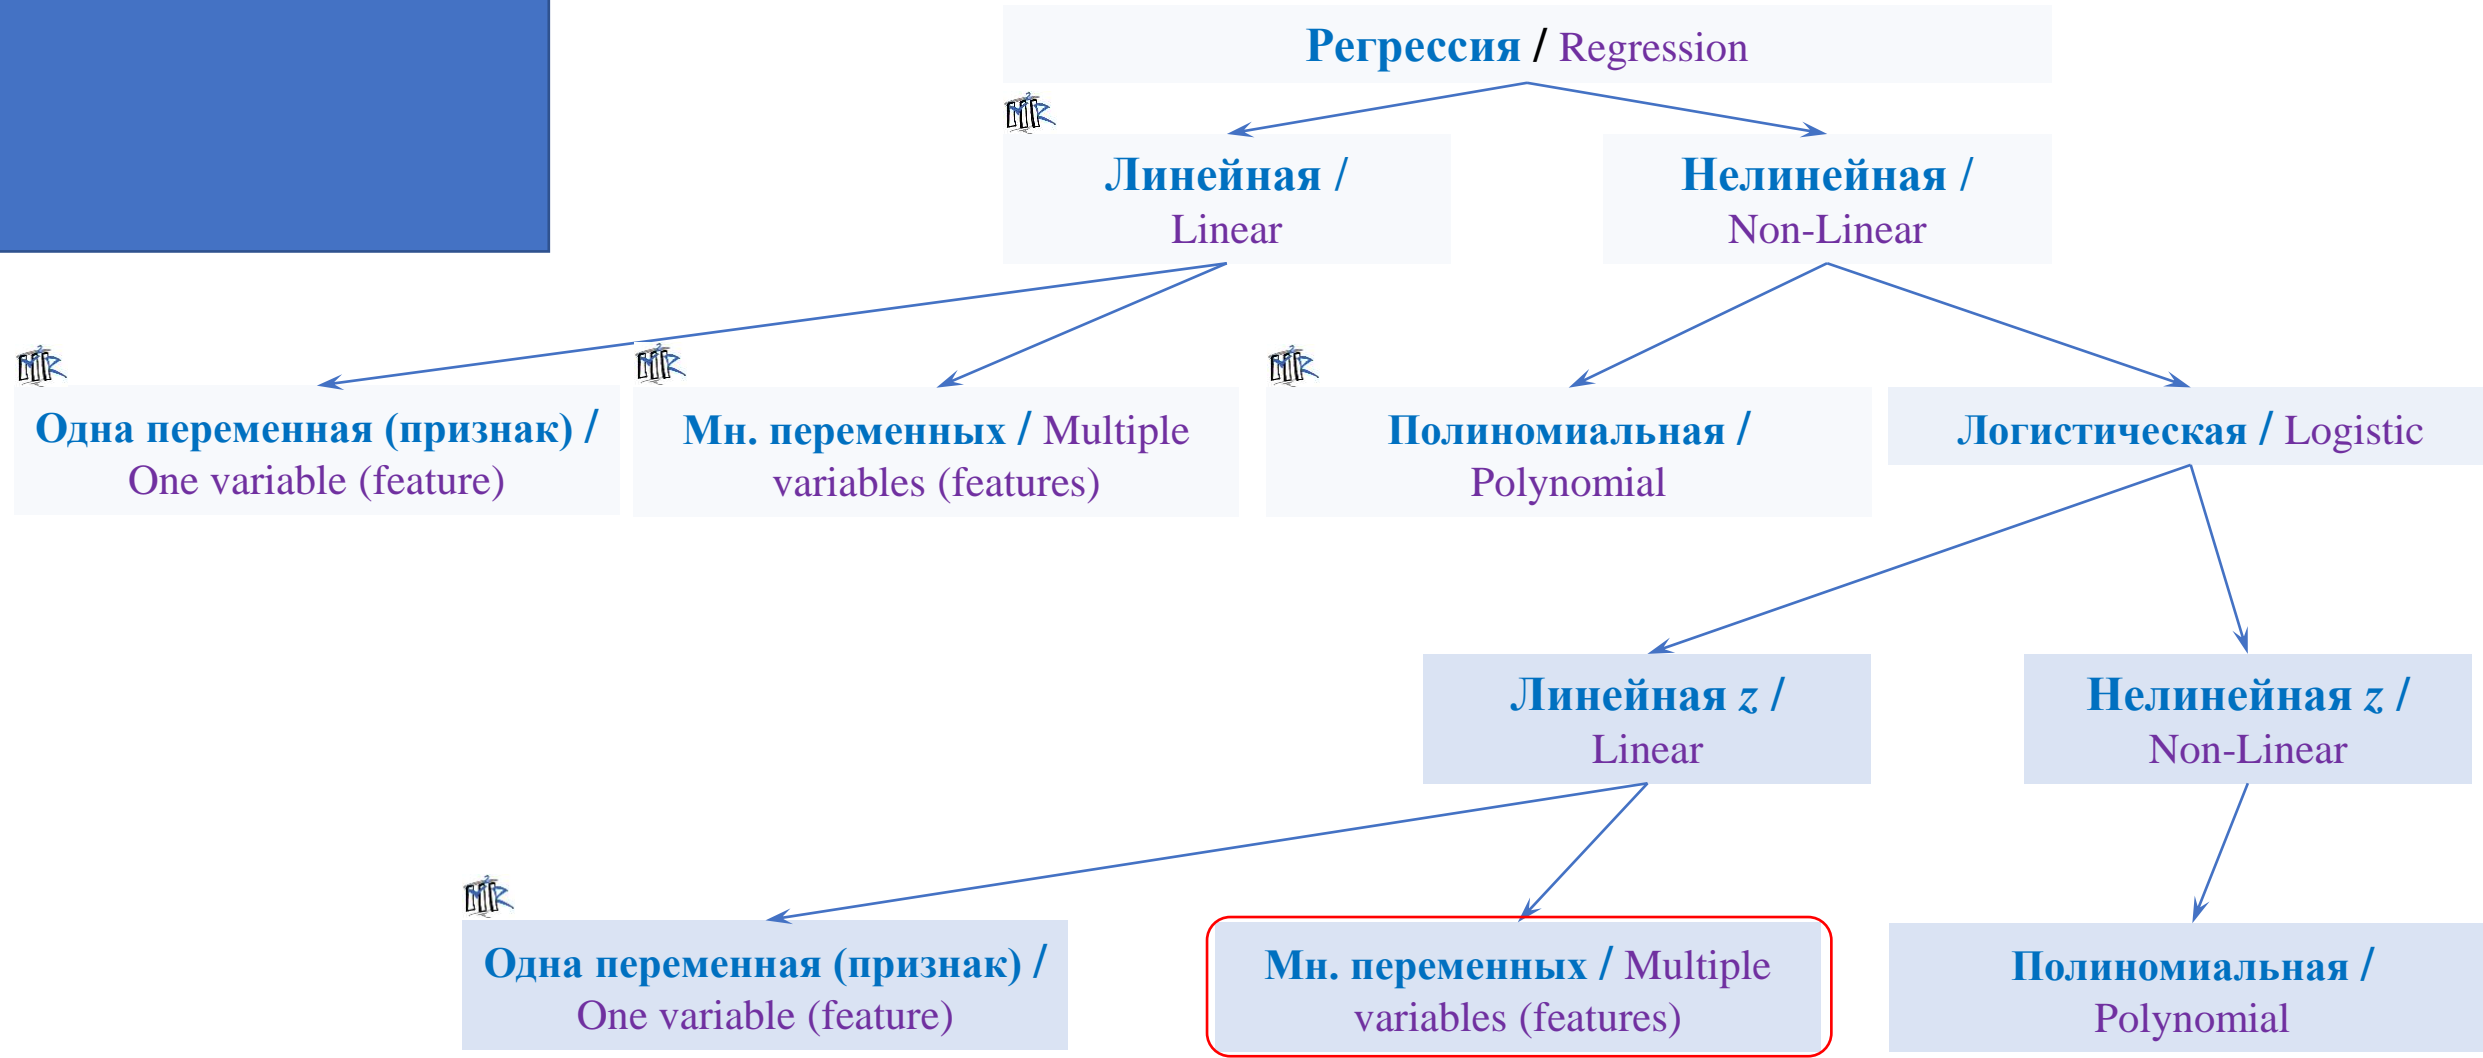
$$\rightarrow J(\Theta) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \ln(h^{(i)}) + (1 - y^{(i)}) \ln(1 - h^{(i)})) \Rightarrow \min, \rightarrow$$

$$\nabla J = \frac{1}{m} X^T (H - Y).$$

Алгоритм поиска минимума функции качества.

1. Задать нач.зн.  $\Theta$  случ. образом.
2. Рассч.  $H = X\Theta$  и  $\nabla J = \frac{1}{m} X^T (H - Y)$ .
3. Найти  $\Theta^H$  :  $\Theta^H = \Theta^C - \alpha \nabla J$ .
4. Повторять пункты 2-3 до выполнения одного из условий:  $J^H - J^C < \delta$ , #итер.  $> N_{max}$ .
5. Вывод результатов:  $\Theta$ .

# Логистическая регрессия и решение задач классификации / Logistic regression and classification



# Логистическая регрессия и решение задач классификации / Logistic regression and classification

Логистическая р. / Logistic r.

1 перем.  $x$  / 1 variable  $x$

Мн.перем.  $x_k$  / Multiple var.  $x_k$   
( $k = 1 \dots n$ )

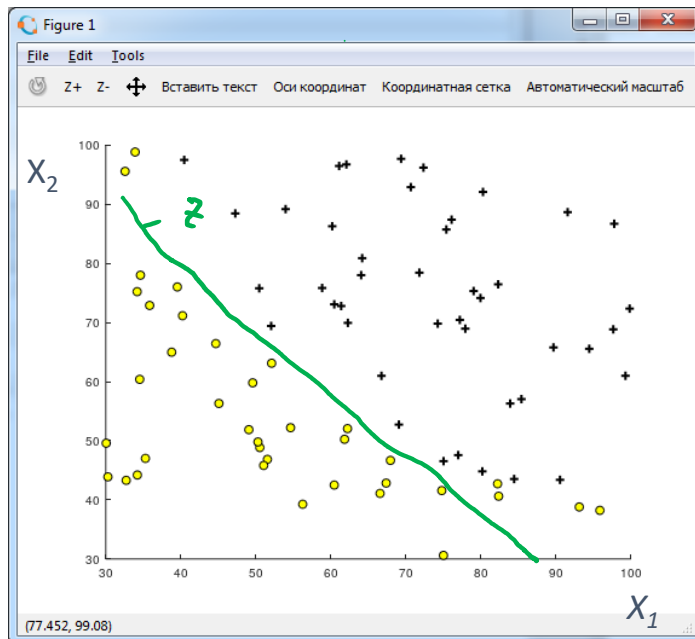
Полином. / Polynomial

$n = 2$

$$X = \begin{pmatrix} \begin{pmatrix} x_1^{(1)} & x_2^{(1)} \\ \vdots & \vdots \\ x_1^{(m)} & x_2^{(m)} \end{pmatrix} \end{pmatrix}; Y = \begin{pmatrix} \begin{pmatrix} y^{(1)} \\ \vdots \\ y^{(m)} \end{pmatrix} \end{pmatrix}; \rightarrow X = \begin{pmatrix} \begin{pmatrix} 1 & x_1^{(1)} & x_2^{(1)} \\ \vdots & \vdots & \vdots \\ 1 & x_1^{(m)} & x_2^{(m)} \end{pmatrix} \end{pmatrix}; \Theta = \begin{pmatrix} \begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{pmatrix} \end{pmatrix}; Z = X\Theta; \rightarrow h(z) = \frac{1}{1+e^{-z}}.$$

$$J(\Theta) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \ln(h^{(i)}) + (1 - y^{(i)}) \ln(1 - h^{(i)})) \Rightarrow \min.$$

$$z = \theta_0 + \theta_1 x_1 + \theta_2 x_2 = 0; \quad x_2 = -\frac{\theta_0}{\theta_2} - \frac{\theta_1}{\theta_2} x_1$$



Алгоритм поиска минимума функции качества.

1. Задать нач.зн.  $\Theta$  сл. образом.
2. Рассч.  $H = X\Theta$  и  $\nabla J = \frac{1}{m} X^T (H - Y)$ .
3. Найти  $\Theta^H$  :  $\Theta^H = \Theta^C - \alpha \nabla J$ .
4. Повторять пункты 2-3 до выполнения одного из условий:  $J^H - J^C < \delta$ , #итер.  $> N_{max}$ .
5. Вывод результатов:  $\Theta$ .  $\nabla = 0$



# Логистическая регрессия и решение задач классификации / Logistic regression and classification

Логистическая р. / Logistic r.

1 перем.  $x$  / 1 variable  $x$

Мн.перем.  $x_k$  / Multiple var.  $x_k$   
( $k = 1 \dots n$ )

Полином. / Polynomial

0 - 4 e 9  
1 - 9

$$X = \begin{pmatrix} \begin{pmatrix} x_1^{(1)} & x_2^{(1)} & \dots & x_n^{(1)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(m)} & x_2^{(m)} & \dots & x_n^{(m)} \end{pmatrix} \end{pmatrix}; Y = \begin{pmatrix} \begin{pmatrix} y^{(1)} \\ \vdots \\ y^{(m)} \end{pmatrix} \end{pmatrix};$$


1h 2h ... nh

$$\rightarrow X = \begin{pmatrix} \begin{pmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \dots & x_n^{(1)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & x_2^{(m)} & \dots & x_n^{(m)} \end{pmatrix} \end{pmatrix}; \Theta = \begin{pmatrix} \begin{pmatrix} \theta_0 \\ \vdots \\ \theta_n \end{pmatrix} \end{pmatrix}; Z = X\Theta;$$

$$\rightarrow h(z) = \frac{1}{1+e^{-z}}.$$

285

$$J(\Theta) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \ln(h^{(i)}) + (1 - y^{(i)}) \ln(1 - h^{(i)})) \Rightarrow \min.$$



Gray scale picture of "Nine"

Алгоритм поиска минимума функции качества.

1. Задать нач.зн.  $\Theta$  случ. образом.
2. Рассч.  $H = X\Theta$  и  $\nabla J = \frac{1}{m} X^T (H - Y)$ .
3. Найти  $\Theta^H$  :  $\Theta^H = \Theta^C - \alpha \nabla J$ .
4. Повторять пункты 2-3 до выполнения одного из условий:  $J^H - J^C < \delta$ , #итер.  $> N_{max}$ .
5. Вывод результатов:  $\Theta$ .

# Логистическая регрессия и решение задач классификации / Logistic regression and classification

Логистическая р. / Logistic r.

1 перем.  $x$  / 1 variable  $x$


Мн.перем.  $x_k$  / Multiple var.  $x_k$

Полином. / Polynomial

$$X = \begin{pmatrix} \begin{pmatrix} x_1^{(1)} & x_2^{(1)} \\ \vdots & \vdots \\ x_1^{(m)} & x_2^{(m)} \end{pmatrix} \end{pmatrix}; Y = \begin{pmatrix} \begin{pmatrix} y^{(1)} \\ \vdots \\ y^{(m)} \end{pmatrix} \end{pmatrix};$$

$$z = \theta_0 + \theta_1 x_1 + \theta_2 x_1^2 + \theta_3 x_1 x_2 + \theta_4 x_2 + \theta_5 x_2^1 \quad h(z) = \frac{1}{1+e^{-z}}.$$

$$J(\Theta) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \ln(h^{(i)}) + (1 - y^{(i)}) \ln(1 - h^{(i)})) \Rightarrow \min.$$



Алгоритм поиска минимума функции качества.

1. Задать нач.зн.  $\Theta$  случ. образом.

2. Рассч.  $H = X\Theta$  и  $\nabla J = \frac{1}{m} X^T (H - Y)$ .

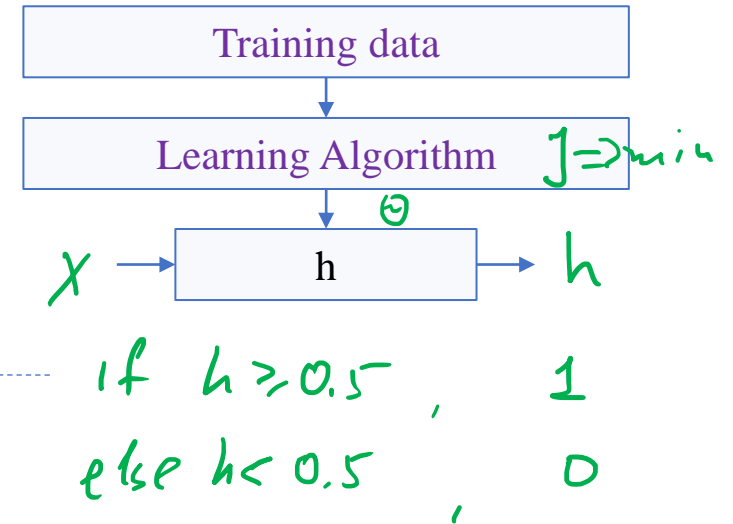


3. Найти  $\Theta^H$  :  $\Theta^H = \Theta^C - \alpha \nabla J$ .

4. Повторять пункты 2-3 до выполнения одного из условий:  $J^H - J^C < \delta$ , #итер.  $> N_{max}$ .



5. Вывод результатов:  $\Theta$ .

# Логистическая регрессия и решение задач классификации / Logistic regression and classification

Классификация. Граница принятия решений / Classification. Decision boundary



$$z = \theta_0 + \theta_1 x_1 + \theta_2 x_2.$$



$$z=0$$

$$z = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1 x_2 + \theta_4 x_1^2 + \theta_5 x_2^2.$$





# Логистическая регрессия и решение задач классификации / Logistic regression and classification

Многоклассовая классификация: один против всех / Multi-class classification: one-vs-all

Основная идея: поиск наилучшей функциональной зависимости мультиарного ( $p$ -арного) множества  $Y = ((y_i))$ ,  $Y \in \{1\ 2\ 3\ \dots\ p\}$ , от множества  $X = ((x_i))$ ,  $X \in R$ ,  $(i=1\dots m)$  по критерию минимума некоторой функции качества  $J(\Theta)$  путем последовательного решения " $p$ " задач двухклассовой классификации ( $p > 2$ ).




Пример. Диагноз: здоров, ОРВИ, грипп (3 класса).  $x_2$

$$X = \begin{pmatrix} x_1^{(1)} & x_2^{(1)} \\ \dots & \dots \\ x_1^{(m)} & x_2^{(m)} \end{pmatrix}; Y = \begin{pmatrix} y^{(1)} \\ \dots \\ y^{(m)} \end{pmatrix}, Y \in \{1\ 2\ 3\}.$$



# Лекция 1. Искусственный интеллект и основы машинного обучения (МО) / Artificial Intelligence (AI) and Machine Learning (ML) basics

1. Область исследования и основные понятия / **Terms**
2. Линейная и полиномиальная регрессия / **Linear and polynomial regression**
3. Логистическая регрессия / **Logistic regression**
4. Настройка МО / **ML settings**



[ML settings intuition](#)

# Настройка моделей МО/ ML settings




**Параметры** модели определяются в ходе решения задачи МО. Например, в задачах регрессии параметрами являются компоненты матрицы  $\Theta$ .

**Гиперпараметры** задаются пользователем, как правило не единственным образом, и их значения **влияют** на значения искомым параметров.

## 1. Масштабирование признаков / Feature Scaling



$$\tilde{x}_i = \frac{x_i}{\max(x_i)}$$





# Настройка моделей МО/ ML settings


**Параметры** модели определяются в ходе решения задачи МО. Например, в задачах регрессии параметрами являются компоненты матрицы  $\Theta$ .

**Гиперпараметры** задаются пользователем, как правило не единственным образом, и их значения **влияют** на значения искомым параметров.

2. Скорость обучения  $\alpha$  / Learning rate

$$\alpha \cdot \nabla J$$

3. Погрешность  $\delta$  и количество итераций  $N_{\max}$  / Error and # of iterations



# Настройка моделей МО/ ML settings




**Параметры** модели определяются в ходе решения задачи МО. Например, в задачах регрессии параметрами являются компоненты матрицы  $\Theta$ .

**Гиперпараметры** задаются пользователем, как правило не единственным образом, и их значения **влияют** на значения искомым параметров.

## 4. Регуляризация / Regularization

$$J(\theta_0, \theta_j) = \frac{1}{2m} \left[ \sum_{i=1}^m (h^{(i)} - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right] \Rightarrow \min.$$


$$h(\theta_0, \theta_j) = \theta_0 + \theta_k x^k, \\ (j, k = 1 \dots n).$$



# Настройка моделей MO/ ML settings



**Параметры** модели определяются в ходе решения задачи МО. Например, в задачах регрессии параметрами являются компоненты матрицы  $\Theta$ .

**Гиперпараметры** задаются пользователем, как правило не единственным образом, и их значения **влияют** на значения искомых параметров.




1. Масштабирование признаков / Feature Scaling
2. Скорость обучения  $\alpha$  / Learning rate
3. Погрешность  $\delta$  и количество итераций  $N_{\max}$  / Error and # of iterations
4. Регуляризация / Regularization


$$J(\Theta) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \ln(h^{(i)}) + (1 - y^{(i)}) \ln(1 - h^{(i)})) + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2 \Rightarrow \min.$$



Недообучение / Underfit,  
High bias



Норм. / Appropriate  
fitting



Переобучение / Overfit,  
High variance

What is underfitting and overfitting

# Самостоятельная работа / Homework

## Вопросы:

1. Почему не рекомендуется дифференцировать функции, полученные в результате регрессионного анализа данных?
2. Почему нельзя сокращать «d» в выражении « $dy/dx$ »?
3. В каких случаях математическое ожидание не совпадает со средним арифметическим значением?
4. Каким образом можно улучшить метод градиентного спуска, чтобы находить с его помощью глобальные минимумы, вместо локальных?
5. Можно ли рассмотренные задачи линейной регрессии решить аналитически, без применения метода градиентного спуска?
6. Почему при построении регрессионных моделей обычно не рекомендуется применение полиномов высоких степеней?